

图神经网络学习进展汇报

针对传统图学习缺陷，梳理 GCN / GraphSAGE / GAT
三代模型的问题迭代改进路线

领域背景：图数据无法用CNN/RNN



迭代① 手工特征不可泛化



迭代② 浅层嵌入



三代GNN分阶段解决

汇报人

刘赋平

日期

2026.08.05



总问题导入：图学习的矛盾主线

本次汇报围绕一条"问题迭代链"展开

① 领域背景前提

图数据无法用 CNN/RNN 处理

节点邻居任意、无固定排列 → 这是整个图深度学习的领域动因，非迭代环节

② 迭代① 手工特征缺陷

手工图特征不可泛化

固定设计、不可学习、新节点需重算全图

③ 迭代② 浅层嵌入缺陷

DeepWalk/Node2Vec 直推式

仅解决特征可学习，直推式/无特征融合仍遗留

④ 三代GNN迭代解决

GCN → GraphSAGE → GAT

各自解决前序痛点，但产生新短板（本次汇报主线）

汇报大纲

每个模块标注对应的问题层级

■ 现存问题/痛点 ■ 对应解决方案 ■ 遗留新问题

01 研究背景

总问题：图数据无法适配传统深度学习

03 图表示学习过渡

浅层嵌入缺陷：直推式、无自适应权重

05 三种经典模型详解

分阶段解决前序模型遗留问题

02 传统图机器学习

旧方法痛点：手工特征不可泛化

04 GNN核心思想

统一解法：消息传递解决图拓扑建模

问题迭代主线

传统方法缺陷 → 浅层嵌入新问题 → GCN解决拓扑建模 → GCN遗留直推+固定权重 → GraphSAGE解决归纳 → GraphSAGE遗留固定权重 → GAT解决自适应权重

研究背景：图数据的机器学习难题

现实世界大量数据天然以图形式存在：社交网络、分子结构、知识图谱、交通路网。核心特征是**节点间存在任意拓扑连接**，而非规则网格或有序序列。



社交网络



分子图



知识图谱

三类核心任务：节点级（分类）· 边级（链接预测）· 图级（性质预测）

为什么需要专门的图深度学习框架

● 痛点 ① 拓扑结构无规则性

节点邻居数量任意、无固定排列 → CNN 卷积核失效、RNN 时序假设失效。

例：社交网络中用户好友数从 0 到上万，无法用固定窗口扫描。

● 痛点 ② 规模与动态性

真实图动辄百万级节点，且节点动态增删 → 传统方法需重算全图，无法增量更新（该问题直至 GraphSAGE 才解决）。

例：Twitter 每日新增百万用户，重训整图显存直接溢出。

● 痛点 ③ 特征与结构割裂

节点有属性特征（文本/画像）又有结构特征（连接关系），传统方法二者分离 → 无法端到端融合。

例：推荐系统中用户画像与社交关系需联合建模，分离处理效果差。

传统图机器学习：手工特征工程

初代解法及其致命缺陷

节点级特征

- 节点度数
- 中心性 (PageRank / 特征向量)
- 聚类系数
- 图元度向量

边级特征

- 最短路径距离
- 共同邻居 / Jaccard
- 局部邻域重叠
- Katz 指数

图级特征

- Graphlet 核
- WL 核
- 度分布 / 直径

● ★ 核心局限 • 手工特征带来的三大待解决问题

① **不可学习**：特征固定设计，无法随任务自适应优化。

例：PageRank 中心性固定，无法为“识别欺诈用户”任务调整权重，

② **无归纳能力**：新节点需重算全图特征。

例：社交平台新用户注册，需重新计算全图中心性，工程不可行，

③ **特征结构割裂**：属性与拓扑分离处理。

例：用户文本画像与社交连接无法联合学习，信息利用不充分，

图表示学习：DeepWalk 与 Node2Vec

解决特征可学习，但遗留核心问题且存在固有局限

● 解决了什么（对应前页痛点①不可学习）

借鉴 NLP 中 Word2Vec，在图上执行随机游走生成"句子"，用 SkipGram 学习节点向量。
特征变为可学习，不再依赖人工设计。

DeepWalk

均匀随机游走

Node2Vec

参数 p/q 控制游走偏向

● ★ 仅解决"特征可学习"，以下问题仍遗留

① 直推式（遗留）：嵌入与图结构绑定，新节点无法生成向量。

例：电商新商品无历史游走记录，无法推荐。

② 无特征融合（遗留）：仅编码连接，忽略节点属性。

例：用户文本画像信息完全丢失。

③ 聚合策略固定：游走策略不可学习，无法随任务优化。

例：欺诈检测与好友推荐需不同聚合方式，固定游走无法适配。

↔ 关键转变：DeepWalk/Node2Vec 把"特征"从固定公式变成可学习向量，但拓扑聚合仍是隐式、固定、与下游任务解耦的——GNN 将聚合变为显式可学习，这正是核心矛盾。

GNN 核心思想：消息传递统一范式

GNN 如何逐一解决前序痛点

痛点① 解法：邻居聚合机制天然适配任意拓扑，不依赖固定网格/序列。

痛点② 解法：参数共享，范式本身具备归纳潜力——但具体模型是否支持归纳取决于实现（GCN 仍直推，GraphSAGE/GAT 支持）。规模性问题需结合邻居采样等工程优化（如 GraphSAGE），范式提供 Mini-batch 训练基础。

痛点③ 解法：节点属性作为初始特征输入，与拓扑结构端到端融合学习。

● 关键伏笔 • 聚合函数 AGGREGATE 的设计差异

统一范式下，AGGREGATE 怎么聚合决定了模型能力。不同聚合策略衍生不同模型，分别解决不同细分问题——这正是后续 GCN / GraphSAGE / GAT 的分化起点。


→ 如何设计 AGGREGATE → GCN 给出第一个答案

为解决前序痛点提供统一框架

消息传递公式

$$h_v^{(k)} = \text{AGGREGATE}^{(\cdot)}(\{ h_u^{(k-1)} : u \in N(v) \}, h_v^{(k-1)})$$

计算图示意（解决多阶拓扑提取）



GCN：图卷积网络

解决了什么：针对浅层嵌入“静态、无特征融合”痛点，给出第一个可端到端训练的聚合方案。

逐层传播公式（每部分对应一个痛点）

$$h^{(l+1)} = \sigma(\hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2} H^{(l)} W^{(l)})$$

$$\hat{A} = A + I$$

加自环 → 解决“自身信息丢失”

$$\hat{D}^{-1/2}$$

对称归一化 → 谱图卷积一阶近似，兼顾数值稳定

$$\hat{A} H^{(l)}$$

邻居求和 → 解决“拓扑信息无法融合”

$$W^{(l)} \cdot \sigma$$

线性变换 → 解决“特征不可学习”

问题导向的四个设计决策

Q1 节点怎么看到邻居？把邻居特征加起来（聚合）

Q2 自身信息丢了？加自环 $\hat{A} = A + I$

Q3 如何从谱图理论导出卷积？对称归一化 $\hat{D}^{-1/2}$ （一阶近似，附带数值稳定）

Q4 聚合后怎么变换？线性变换 W + 非线性 σ

★ GCN 遗留问题 → 分别由 GraphSAGE / GAT 解决

① 直推式：需整图训练，新节点需更新全图矩阵重算，效率低。例：百万级社交图每日新增用户，重训整图显存溢出


② 固定权重聚合：权重由拓扑结构决定、不可学习，无法区分邻居重要性。例：知识图谱中噪声关系与关键关系一视同仁

③ 有向图受限：依赖对称归一化（GCN自身新限制）。例：有向引文网络效果差

GraphSAGE: 采样与聚合

解决了什么：针对 GCN 直推式、需整图训练痛点。归纳能力源于聚合函数参数化、不依赖全图拉普拉斯；采样解决计算效率与显存，支持 Mini-batch。

采样机制 → 解决显存与效率



每层仅采样 K 个邻居 → 显存恒定，解决 GCN 全图训练显存爆炸

$$h_{u_i}^{(l)} = A \cdot G(\{h_u^{(l)} \mid u \in N(v)\})$$

$$h_v^{(l+1)} = \sigma(W \cdot \text{CONCAT}(h_v^{(l)}, h_{N(v)}^{(l)}))$$

一般聚合器 → 各自的局限

Σ Mean 取邻居均值

局限：等价 GCN 固定权重，无法区分邻居重要性。

Pooling 先变换再取max

局限：max 是硬选择，信息损失大，权重仍非显式可学习。

● ★ 遗留问题 + 自身新短板 → 引出 GAT

遗留（未解决）：Mean/Pooling 聚合权重均非显式可学习，权重固定、无法区分邻居重要性。
例：推荐系统中活跃用户与冷启动用户同等对待，


新增（自身代价）：采样带来信息损失与估计方差，采样数 K 需人工调优，固定采样难以适应邻居分布差异。

→ 固定权重痛点 → GAT 注意力自适应权重

GAT: 图注意力网络

解决了什么：针对 GraphSAGE 聚合权重不可学习、无法区分邻居重要性痛点，引入注意力机制自适应学习权重，附带解决 GCN 有向图问题。

注意力权重 → 解决固定权重缺陷



边粗细 = 注意力权重 α_{ij} 自适应分配 → 解决 GraphSAGE 固定权重缺陷

$$\alpha_{ij} = \text{softmax}_j(\text{LeakyReLU}(\mathbf{a}^T [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j]))$$

三大优势 → 对应解决前序痛点

- ✓ 自适应权重：解决 GCN/GraphSAGE 固定权重痛点
- ✓ 支持有向图：注意力基于节点对，不依赖对称性
- ✓ 多头注意力：K个独立注意力并行，捕捉多重邻域关系、增强表达力
- ✓ 归纳能力：无需整图拉普拉斯，可泛化新节点

● ★ GAT 自身代价与遗留痛点（迭代链条开放收尾）

计算开销大：复杂度与边数线性相关，多头进一步放大。百万级知识图谱比 GCN 慢 3-5 倍。

遗留问题：注意力易受噪声边干扰、深层网络过平滑、复杂度随边数增长——这些是后续研究（如稀疏注意力、过平滑缓解）的切入点。



THANK YOU

感谢聆听

欢迎各位老师与同学批评指正